

# DrivingGaussian

30 сентября 2025 г.

# Содержание

|   |                                               |   |
|---|-----------------------------------------------|---|
| 1 | Мат. аппарат и определения                    | 3 |
| 2 | Описание Gaussian Splatting                   | 4 |
| 3 | Описание 3D-GS                                | 4 |
| 4 | Incremental Static 3D Gaussians               | 4 |
| 5 | Приоритет LiDAR с учетом окружающих видов     | 6 |
| 6 | Глобальный рендеринг через Gaussian Splatting | 7 |

# 1 Мат. аппарат и определения

**Определение.** Векторное поле – это отображение из  $S \subset \mathbb{R}^n \mapsto \mathbb{R}^n$ , сопоставляющее каждой точке вектор. В нашем случае из  $S \subset \mathbb{R}^3 \mapsto \mathbb{R}^3$ .

**Определение.** Пусть заданы  $\bar{G} \subset \mathbb{R}^2$  замкнутая ограниченная область с границей  $\partial G$  – простым кусочно-гладким контуром.  $\Sigma$  – простая гладкая поверхность, заданная отображением  $x : \bar{G} \mapsto \mathbb{R}^3$  и ориентированная одним из двух непрерывных полей единичных нормалей

$$n(x) = \pm \frac{[x'_{t1}, x'_{t2}]}{\|[x'_{t1}, x'_{t2}]\|_2} : \Sigma \setminus \partial\Sigma \mapsto \mathbb{R}^3$$

Далее пусть задано векторное поле  $F = (F^1, F^2, F^3) : \Sigma \setminus \partial\Sigma \mapsto \mathbb{R}^3$ . Тогда потоком векторного поля  $F$  через ориентированную поверхность  $\Sigma$  называется величина

$$\iint_{\Sigma} F d\sigma = \pm \iint_G \langle F, \|[x'_{t1}, x'_{t2}]\|_2 \rangle dt$$

где  $\langle a, b \rangle$  – скалярное произведение.

**Замечание.** Чтобы лучше понять, что понятие потока векторного поля, посмотрите физическую интерпретацию этого понятия в законе Гаусса.

**Определение.** Набор случайных величин  $\xi = (\xi_1, \dots, \xi_n)$  имеет *многомерное нормальное распределение*, если:

1.  $\exists a = (a_1, \dots, a_n)$ , где  $a_i \in \mathbb{R}$ . Этот вектор называется *вектором средних многомерных нормального распределения*.
2.  $\exists C = (c_{ij})$  – матрица, в которой  $c_{ij} \in \mathbb{R}$
3.  $\exists$  набор независимых стандартных нормальных случайных величин  $\eta = (\eta_1, \dots, \eta_n)$  (то есть  $\eta_i \sim \mathcal{N}(0, 1)$ ) для которых выполнено

$$\begin{cases} \xi_1 = a_1 + c_{11}\eta_1 + \dots + c_{1n}\eta_n \\ \dots \\ \xi_n = a_n + c_{n1}\eta_1 + \dots + c_{nn}\eta_n \end{cases} \iff \xi = a + C\eta$$

**Определение.** Матрица ковариации  $B = (b_{ij})$  называется матрица, такая что  $(b_{ij}) = cov(\xi_i, \xi_j)$

**Замечание.** Матрицы связаны следующим образом:  $B = B \cdot B^T$

## 2 Описание Gaussian Splatting

**Определение.** GS – это гибридный метод объемной визуализации.

Сцена для GS – это массив примитивов. Примитивы обладают следующими параметрами:

1.  $(x, y, z)$  – координаты положения центра масс Гауссиана в пространстве.
2. Для многомерного нормального (гауссовского) распределения нужна ковариационная матрица размерности  $3 \times 3$ , которая показывает, насколько вытянут или сплюснут эллипсоид.
3. Альфа-канал (дополнительный канал, который хранит информацию о прозрачности, позволяя создавать частичную или полную прозрачность элементов)
4. RGB

## 3 Описание 3D-GS

3D-GS – это фреймворк для создания сцен динамического вождения. Он моделирует статическую сцену с помощью множества трехмерных гауссов. Для сложных сцен с движущимися объектами сначала последовательно моделируем статический фон всей сцены с помощью дополнительных статических 3D-гауссиан. Затем мы используем составной динамический гауссовский граф для обработки множества движущихся объектов, индивидуально реконструируя каждый объект и восстанавливая их точное положение и взаимосвязи между перекрытиями в пределах сцены. Далее мы используем лидарный анализатор для гауссовского разбрызгивания для реконструкции сцены с большей детализацией и сохранением панорамной целостности.

[Репозиторий с фреймворком](#)

[Классическая реализация SfM](#)

[Введение в 3D-GS](#)

[Дифференциальная гауссовская растеризация](#)

## 4 Incremental Static 3D Gaussians

**Проблемы:**


- По мере движения эго-машины статический фон часто претерпевает временные сдвиги и изменения.
- Из-за принципа перспективы (проблема точки схода) предварительная интеграция отдаленных уличных сцен с разных временных шагов, находящихся далеко от текущей камеры, может привести к путанице масштаба, неприятным артефактам и размытости.

**Решение:** Улучшаем 3D-GS, вводя инкрементальные статические 3D Гауссианы, используя изменения перспективы, вызванные движением машины, и временные отношения между соседними кадрами.

1. Делим статическую сцену на  $N$  бинов на основе диапазона глубины, предоставленного LiDAR. Бины располагаются в хронологическом порядке, обозначаемом как  $b_i^N$ , где каждый бин содержит изображения с одной или нескольких временных точек.
2. Для сцены внутри первого бина мы инициализируем модель Гауссиана, используя LiDAR (аналогично применимый к точкам SfM):

$$p_{b_0}(l|\mu, \Sigma) = e^{-\frac{1}{2}(l-\mu)^T \Sigma^{-1}(l-\mu)}$$

где  $l \in \mathbb{R}^3$  — позиция LiDAR;  $\mu$  — среднее значение точек LiDAR;  $\Sigma \in Mat_{3 \times 3}(\mathbb{R})$  — анизотропная матрица ковариации; и  $T$  — оператор транспонирования.



3. Для следующих бинов используем Гауссианы из предыдущего бина в качестве прежних позиций и выравниваем смежные бины на основе их перекрывающихся регионов. 3D-центр для каждого бина может быть определен

как:

$$\hat{P}_{b+1}(G_s) = P_b(G_s) \cup (x_{b+1}, y_{b+1}, z_{b+1})$$

где  $\hat{P}$  – это коллекция 3D-центров для Гауссиан  $G_s$  всех в данный момент видимых регионов,  $(x_{b+1}, y_{b+1}, z_{b+1})$  – координаты Гауссиан внутри региона  $b+1$ .

4. Итеративно мы добавляем сцены из последующих бинов в ранее построенные Гауссианы с использованием нескольких окружающих кадров. Инкрементальная статическая модель Гауссиан  $G_s$  может быть определена как:

$$\hat{C}(G_s) = \sum_{b=1}^N \Gamma_b \alpha_b C_b, \quad \Gamma_b = \prod_{i=1}^{b-1} (1 - \alpha_i)$$

где  $C$  – цвет, соответствующий каждому одиночному Гауссиану при определенном ракурсе,  $\alpha$  – непрозрачность, а  $\Gamma$  – накопленная пропускаемость сцены в соответствии с  $\alpha$  по всем бином. Во время этого процесса перекрывающиеся регионы между окружающими изображениями с нескольких камер используются для совместного выравнивания моделей Гауссиан.

5. Обратите внимание, что во время инкрементального построения статических моделей Гауссиан могут возникнуть различия в сэмплировании одной и той же сцены между передней и задней камерами. Чтобы устранить это, мы применяем взвешенное усреднение для точной реконструкции цветов сцены, насколько это возможно, во время 3D-проекции Гауссиан:

$$\hat{C} = s(G_s) \sum w(\hat{C}(G_s) | R, T)$$

где  $\hat{C}$  – оптимизированный цвет пикселя,  $s$  – дифференциальное сплаттинг,  $w$  – вес для разных ракурсов,  $[R, T]$  – матрица вида для выравнивания видов с нескольких камер.

## 5 Приоритет LiDAR с учетом окружающих видов

**Проблема:** 3D-GS пытается инициализировать Гауссианы через SfM. Однако неограниченные городские сцены для автономного вождения содержат множество многоуровневых фонов и передних планов. Тем не менее, они видны только через чрезвычайно разреженные ракурсы, что приводит к трудоемкому и неполному восстановлению геометрических структур.

**Решение:** Для лучшей инициализации Гауссиан мы вводим приоритет LiDAR для 3D Гауссиан, чтобы получить более точные геометрии и поддерживать согласованность между несколькими камерами в регистрации окружающих видов.

1. Пусть  $t \in T$  – временной шаг;  $\{I_t^i\}_{i=1}^N$  – набор изображений с нескольких камер, собранных с движущейся платформы;  $L_t$  – многокадровые сканирования LiDAR.
2. Хотим: минимизировать ошибки регистрации между камерами, используя данные LiDAR-изображений, и получить точные позиции точек и геометрические приоритеты.
3. Сначала мы объединяем несколько кадров сканирований LiDAR, чтобы получить полное облако точек сцены, обозначаемое как  $L$ . Мы следуем Colmap и извлекаем признаки изображения  $X = x_q^p$  из каждого изображения индивидуально.
4. Затем мы проецируем точки LiDAR на окружающие изображения. Для каждой точки LiDAR  $l$  мы преобразуем ее координаты в систему координат камеры и сопоставляем ее с 2D-пикселем изображения камеры через проекцию:

$$x_q^p = K[R_t^i \cdot l_s + T_t^i]$$

где  $x_q^p$  – 2D-пиксель изображения,  $R_t^i, T_t^i$  – ортогональные матрицы вращения и векторы трансляции соответственно,  $K \in Mat_{3 \times 3}(\mathbb{R})$  – известная внутренняя матрица камеры.

Точки из LiDAR могут проецироваться на несколько пикселей на нескольких изображениях. Поэтому мы выбираем точку с наименьшим евклидовым расстоянием до плоскости изображения и сохраняем ее как проецированную точку, присваивая цвет. Аналогично предыдущим работам в 3D-реконструкции, мы расширяем плотную корректировку пучков (DBA) на настройку нескольких камер и получаем обновленные точки LiDAR.

## 6 Глобальный рендеринг через Gaussian Splatting

Мы используем дифференцируемый рендерер 3D Gaussian splatting и проецируем глобальный композитный 3D Gaussian в 2D, где матрица ковариации  $\tilde{\Sigma}$  дана как:

$$\tilde{\Sigma} = (JE)\Sigma(JE)^T$$

где  $J$  — якобиан матрица перспективной проекции;  $E$  обозначают матрицу world-to-camera.

Композитное Гауссианское поле проецирует глобальный 3D Гауссиан на несколько 2D-плоскостей и контролируется с использованием окружающих видов на каждом временном шаге. В процессе глобального рендеринга Гауссианы из следующего временного шага изначально невидимы для текущего и последующего шага и последовательно интегрируются с использованием соответствующих глобальных изображений в качестве надзора. Функция потерь нашего метода состоит из трех частей. Мы сначала вводим Tile Structural Similarity (TSSIM) для Gaussian Splatting, что измеряет схожесть между отрисованным тайлом и соответствующей истинной разметкой.

$$L_{TSSIM}(\delta) = 1 - \frac{1}{Z} \sum_{z=1}^Z SSIM(\Psi(\hat{C}), \Psi(C))$$

где мы делим экран на  $M$  тайлов,  $\delta$  — параметры обучения Гауссиан,  $\Psi(\hat{C})$  обозначает отрисованный тайл из Composite Gaussian Splatting, а  $\Psi(C)$  обозначает парный истинный тайл. Мы также вводим робастную (независимую от выбросов) потерю для уменьшения выбросов в 3D Гауссианах, которая может быть определена как:

$$L_{Robust}(\delta) = \kappa \|\hat{I} - I\|_2$$

где  $\kappa \in (0, 1]$  — параметр формы, который контролирует робастность потери,  $I$  и  $\hat{I}$  обозначают истинное и синтезированное изображение соответственно. Потеря LiDAR дополнительно используется для контроля ожидаемых позиций Гауссиан с помощью LiDAR, получая лучшую геометрическую структуру и формы краев:

$$L_{LiDAR}(\delta) = \frac{1}{s} \sum \|P(G_{comp}) - L_s\|^2$$

где  $P(G_{comp})$  — позиция 3D Гауссиан, а  $L_s$  — приоритет точки LiDAR. Мы оптимизируем Композитные Гауссианы, минимизируя сумму трех потерь.